Análise Estatística de um Experimento de Redução da Glicemia

Limpeza de dados e inferência estatística sobre a eficácia de tratamentos medicamentosos e da dieta

Kaike Martins

Outubro de 2026

Dados fictícios (mock), gerados exclusivamente para fins didáticos.
Este relatório demonstra a metodologia e não constitui estudo clínico real.

Sumário

1. Introdução e objetivo 3
2. Metodologia 3
2.1 Aquisição dos dados 3
2.2 Preparação e limpeza 3
3. Resultados 4
3.1 Efeito do tratamento na glicemia 4
3.2 Comparação entre os medicamentos 5
3.3 Influência da dieta 5
3.4 Confiabilidade dos resultados sobre a dieta 6
4. Discussão integrada 6
5. Limitações do estudo 7
6. Conclusão 7
7. Referências 7

1. Introdução e objetivo

Nota sobre os dados. Os dados utilizados são fictícios (mock), criados para fins didáticos de preparação e análise de dados. As conclusões ilustram a aplicação do método estatístico e não representam um estudo clínico real.

Este trabalho analisa os resultados de um experimento de redução da glicemia realizado com 500 pacientes. Cada paciente teve a glicemia medida antes e depois de um tratamento, recebeu exclusivamente um de dois medicamentos (Remédio 1 ou Remédio 2) e seguiu, ou não, uma dieta. O objetivo é aplicar métodos estatísticos para avaliar a eficácia dos tratamentos medicamentosos e verificar se a dieta influencia a redução da glicemia, adotando nível de significância de 5% e nível de confiança de 95%.

O trabalho foi conduzido em duas fases. A primeira, de **aquisição e preparação dos dados**, tratou uma base propositalmente suja, a etapa avaliada pela disciplina e condição indispensável para que os testes produzam resultados confiáveis. A segunda, de **análise estatística**, aplicou testes de hipótese sobre a base já limpa. Ferramentas utilizadas: Python, com a biblioteca pandas para manipulação e limpeza e a biblioteca SciPy (módulo stats) para os testes de hipótese.

2. Metodologia

2.1 Aquisição dos dados

Os dados foram lidos diretamente do arquivo-fonte disponibilizado pela plataforma da FMU (arquivo de texto separado por vírgula, codificação UTF-8), evitando-se intencionalmente a abertura e o salvamento em planilha eletrônica, procedimento que altera separador e codificação sem aviso e corrompe os acentos. Essa decisão garante que a análise parta da fonte original e íntegra.

2.2 Preparação e limpeza

O diagnóstico inicial revelou que a contagem de valores ausentes era zero em todas as colunas, o que não indicava base limpa: o problema não era a ausência de dados, e sim a presença de valores inválidos disfarçados de válidos (glicemias negativas, datas impossíveis, grafias inconsistentes). Adotou-se, portanto, uma estratégia em duas camadas, primeiro o formato, depois a plausibilidade e um princípio norteador: o rigor da limpeza deve ser proporcional ao uso de cada coluna. Colunas usadas nas análises (glicemia, medicamento, dieta), quando inválidas, justificaram a remoção do registro; colunas não usadas (datas, identificador, nome) foram reparadas ou marcadas como ausentes, sem jamais descartar o paciente.

As principais decisões de limpeza foram:

- **Indicadores Sim/Não (Remédio 1, Remédio 2, Dieta):** as grafias caóticas (Sim, sim, SIM, s, Yes, 1, Não, nao, N, 0, entre outras) foram normalizadas (remoção de espaços e conversão para minúsculas) e mapeadas para os valores canônicos "Sim" e "Não". Os valores 1 e 0 foram interpretados como Sim e Não seguindo convenção booleana.
- **Regra lógica de um medicamento por paciente:** 38 registros violavam a regra (26 com os dois remédios assinalados e 12 com nenhum) e foram removidos por impossibilidade lógica. A partir das colunas válidas, derivou-se a variável única "Medicamento".

- **Glicemia (camada 1 - formato):** valores com unidade anexada ("190 mg/dL") e com vírgula decimal ("108,5") foram recuperados e convertidos para número, pois o valor verdadeiro era conhecível sem suposição.
- **Glicemia (camada 2 - plausibilidade):** valores fisiologicamente impossíveis (negativos, extremos acima de 500 e valores em escala incompatível) foram invalidados. Adotou-se uma faixa plausível de 20 a 500 mg/dL, justificada tanto pelo conhecimento de domínio quanto por um intervalo vazio na própria distribuição (os valores reais iam até ~273 e o grupo de erros começava em ~557). Optou-se deliberadamente por validação por faixa fisiológica, e não por detecção estatística de outliers, que descartaria glicemias altas porém reais. 69 registros com glicemia inválida foram removidos, após verificação de que o descarte era equilibrado entre os grupos.
- **Datas (formato):** os três campos de data misturavam formatos (dd/mm/aaaa, dd.mm.aaaa, dd-mm-aaaa, ISO, ano com dois dígitos e datas por extenso em português). Foram convertidos por interpretação individual de cada valor e por mapeamento dos nomes de meses em português.
- **Datas (lógica):** 25 registros apresentavam data de fim anterior à de início; a inspeção mostrou que, ao inverter as colunas, todos resultavam em tratamentos coerentes e com duração plausível, evidenciando troca de colunas que foram recuperados por inversão. Outros 10 registros tinham data de nascimento impossível (posterior ao tratamento); sem evidência para recuperar o valor real, foram marcados como ausentes, preservando-se as linhas.
- **Identificador e nome:** o Id foi padronizado para o formato P0000 e os espaços excedentes dos nomes foram removidos. Não se corrigiram erros de digitação em nomes, por não haver como determinar a grafia correta.

Resultado da preparação: da base original de 500 registros, restaram **393 registros válidos** (38 removidos por violação da regra de medicamento e 69 por glicemia fora da faixa fisiológica). Por fim, criou-se a variável de análise **Redução = Glicemia inicial – Glicemia final**.

3. Resultados

Para cada questão foram definidas as hipóteses estatísticas, escolhido o teste adequado com sua justificativa e interpretado o resultado. Em todos os testes adotou-se $\alpha = 0{,}05$.

3.1 Efeito do tratamento na glicemia

Hipóteses. H_0: a redução média verdadeira é igual a zero (o tratamento não altera a glicemia). H_1: a redução média verdadeira é diferente de zero.

Teste e justificativa. Teste t pareado. Justifica-se por serem duas medições do mesmo paciente (antes e depois): o pareamento compara cada indivíduo consigo mesmo, cancelando a variação entre pessoas e isolando o efeito do tratamento.

Resultado. $t = 23{,}93$; $p < 0{,}001$ ($\approx 1{,}2 \times 10^{-78}$). A glicemia média caiu de 164,6 para 132,4 mg/dL, uma redução média de aproximadamente 32 mg/dL.

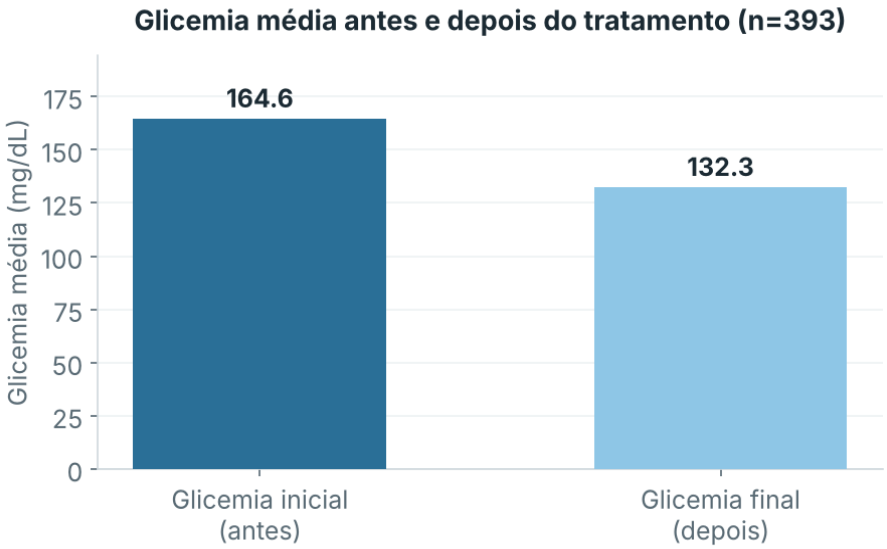


Figura 1 — Glicemia média antes e depois do tratamento (n = 393).

Interpretação. Rejeita-se H_0: há redução estatisticamente significativa da glicemia entre o início e o fim do tratamento. Ressalva-se que o desenho antes-depois, sem grupo controle, demonstra que a glicemia caiu, mas não permite atribuir isoladamente a queda ao medicamento.

3.2 Comparação entre os medicamentos

Hipóteses. H_0: a redução média é igual entre Remédio 1 e Remédio 2. H_1: as reduções médias são diferentes.

Teste e justificativa. Teste t para amostras independentes (versão de Welch, que não pressupõe variâncias iguais). Justifica-se por comparar dois grupos distintos de pacientes (n = 209 no Remédio 1 e n = 184 no Remédio 2), de tamanhos e variabilidades diferentes.

Resultado. Redução média de 36,8 mg/dL (Remédio 1) contra 27,1 mg/dL (Remédio 2); $t = 3{,}61$; $p < 0{,}001$ ($\approx 0{,}00035$); diferença de 9,7 mg/dL, com IC 95% de [4,4 ; 15,0].

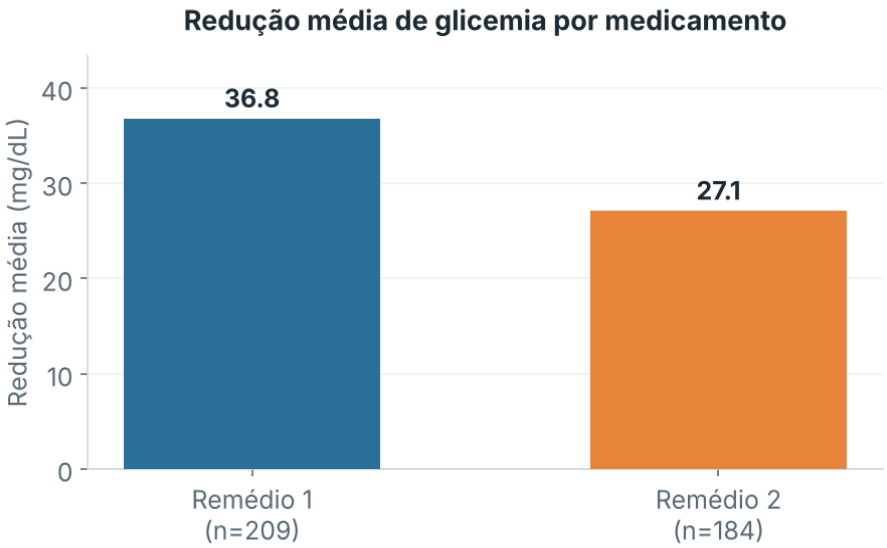


Figura 2 — Redução média de glicemia por medicamento.

Interpretação. Rejeita-se H_0: há diferença significativa entre os medicamentos, e o Remédio 1 apresenta redução cerca de 9,7 mg/dL maior. Por se tratar de dado observacional (sem alocação aleatória dos pacientes aos medicamentos), a vantagem não pode ser atribuída exclusivamente ao fármaco.

3.3 Influência da dieta

Controle de confusão. Antes de comparar, verificou-se se a dieta estava confundida com o medicamento. A proporção de medicamentos mostrou-se equilibrada entre os grupos de dieta (≈ 55% de Remédio 1 entre quem não fez dieta e ≈ 52% entre quem fez), o que afasta o medicamento como variável de confusão e torna a comparação direta confiável.

Hipóteses. H_0: a redução média é igual entre quem seguiu e quem não seguiu a dieta. H_1: as reduções médias são diferentes.

Teste e justificativa. Teste t de Welch para amostras independentes (grupos distintos: n = 198 com dieta e n = 195 sem dieta).

Resultado. Redução média de 39,8 mg/dL (com dieta) contra 24,6 mg/dL (sem dieta); t = 5,90; p < 0,001 (≈ $8{,}5 \times 10^{-9}$); diferença de 15,2 mg/dL.

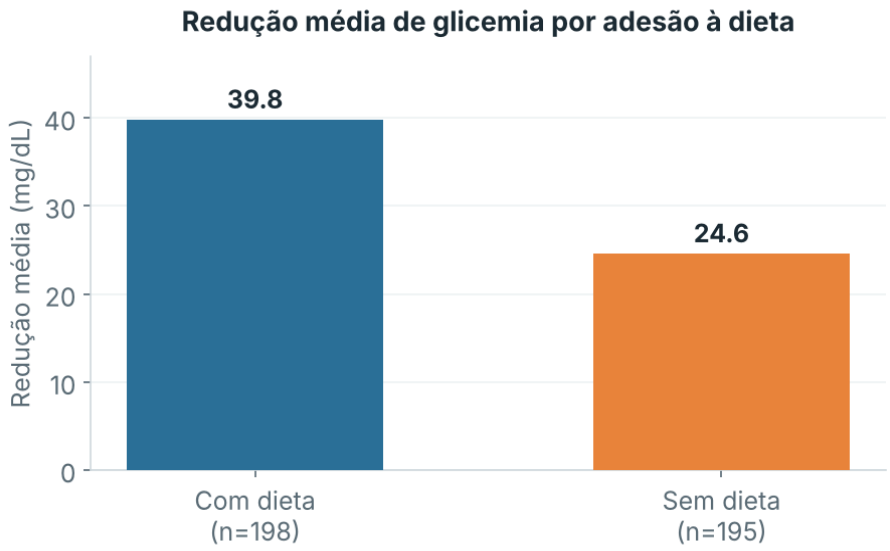


Figura 3 — Redução média de glicemia conforme adesão à dieta.

Interpretação. Rejeita-se H_0: seguir a dieta está associado a uma redução significativamente maior da glicemia. Afastado o medicamento como confundidor, a associação é sólida.

3.4 Confiabilidade dos resultados sobre a dieta

Valor-p e intervalo de confiança. A vantagem estimada da dieta é de 15,2 mg/dL, com valor-p ≈ $8{,}5 \times 10^{-9}$ e intervalo de confiança de 95% entre 10,1 e 20,3 mg/dL. Por estar inteiramente acima de zero, o intervalo confirma a significância (não inclui o efeito nulo) e ainda dimensiona o efeito: estima-se, com 95% de confiança, que a vantagem real da dieta situa-se entre cerca de 10 e 20 mg/dL. Esse efeito é, inclusive, superior à diferença entre os medicamentos (~9,7 mg/dL).

Limitações e causalidade. Verificou-se e afastou-se apenas um confundidor (o medicamento); outros fatores não medidos como disciplina, exercício, adesão ao tratamento, hábitos de vida podem influenciar simultaneamente a decisão de fazer dieta e a redução da glicemia. Como os pacientes escolheram aderir ou não à dieta, em vez de serem alocados aleatoriamente,

os dados não permitem afirmar que a dieta causa a redução da glicemia. A conclusão estatisticamente sustentável é de associação, não de causa. O estabelecimento de causalidade exigiria um estudo com randomização (sorteio dos pacientes entre fazer e não fazer dieta), único desenho capaz de neutralizar também os confundidores não medidos.

4. Discussão integrada

Qual medicamento é mais eficaz? O Remédio 1, com redução média cerca de 9,7 mg/dL superior à do Remédio 2, diferença estatisticamente significativa ($p < 0,001$).

A dieta está associada a redução adicional? Sim. Quem seguiu a dieta reduziu, em média, 15,2 mg/dL a mais, com forte significância estatística e intervalo de confiança afastado do zero, efeito maior, inclusive, que o do próprio medicamento.

O que é sustentável estatisticamente? São sustentáveis as afirmações de associação: o tratamento reduz a glicemia, o Remédio 1 supera o Remédio 2 e a dieta acompanha maior redução. Não é sustentável qualquer afirmação de causalidade, por se tratar de estudo observacional sem randomização nem grupo controle.

Os dados são estruturados, semiestruturados ou não estruturados? Estruturados: organizam-se em tabela, com linhas (pacientes) e colunas de esquema definido e tipos fixos. Vale a distinção de que o dado estruturado não é sinônimo de dado limpo: esta base era altamente estruturada e, ao mesmo tempo, intensamente suja.

5. Limitações do estudo

- Desenho observacional, sem randomização nem grupo controle, o que impede conclusões de causalidade.
- Redução da amostra de 500 para 393 registros válidos (21%) em razão da limpeza necessária.
- Possíveis variáveis de confusão não medidas (hábitos, adesão, estilo de vida), especialmente na análise da dieta.
- Alguns valores e datas ambíguos não puderam ser recuperados sem suposição e foram invalidados.

6. Conclusão

A preparação cuidadosa dos dados foi determinante: sem ela, os valores inválidos (glicemias negativas e extremas, datas impossíveis, registros logicamente contraditórios) teriam contaminado os testes de forma silenciosa. Sobre a base limpa de 393 registros, os testes indicaram, de forma estatisticamente significativa, que o tratamento reduz a glicemia, que o Remédio 1 é mais eficaz que o Remédio 2 e que a adesão à dieta está associada a uma redução adicional expressiva. Todas as conclusões são de associação; a natureza observacional dos dados não autoriza afirmações de causalidade.

Síntese dos resultados:

Análise	Teste	valor-p	Conclusão
1. Tratamento (antes × depois)	t pareado	< 0,001	Redução significativa (~32 mg/dL)
2. Remédio 1 × Remédio 2	t de Welch	< 0,001	Remédio 1 superior (~9,7 mg/dL)
3. Dieta × sem dieta	t de Welch	< 0,001	Dieta associada a maior redução (~15,2 mg/dL)
4. Confiabilidade da dieta	IC 95%	[10,1 ; 20,3]	Associação sólida; sem prova de causa

7. Referências

BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 9. ed. São Paulo: Saraiva, 2017.

McKINNEY, W. Data Structures for Statistical Computing in Python. In: Proceedings of the 9th Python in Science Conference, 2010, p. 56–61.

VIRTANEN, P. et al. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. Nature Methods, v. 17, p. 261–272, 2020.

WELCH, B. L. The generalization of 'Student's' problem when several different population variances are involved. Biometrika, v. 34, n. 1-2, p. 28–35, 1947.